## A3

## May 11, 2023

```
[1]: import requests
      import zipfile
 [2]: url = "https://download.inep.gov.br/microdados/
       ⇒microdados_censo_da_educacao_superior_2021.zip"
 [3]: r=requests.get(url, verify=False)
     /opt/conda/lib/python3.10/site-packages/urllib3/connectionpool.py:1045:
     InsecureRequestWarning: Unverified HTTPS request is being made to host
     'download.inep.gov.br'. Adding certificate verification is strongly advised.
     See: https://urllib3.readthedocs.io/en/1.26.x/advanced-usage.html#ssl-warnings
       warnings.warn(
 [4]: with open("r.zip", "wb") as f:
          f.write(r.content)
 [5]: with zipfile.ZipFile("r.zip", "r") as zip_ref:
          zip ref.extractall("./data")
         importanto sparksession
 [6]: from pyspark.sql import SparkSession
 [7]: spark = SparkSession \
      .config("spark.sql.repl.eagerEval.enabled", "True") \
      .config("spark.sql.repl.eagerEval.maxNumRows", "10") \
      .getOrCreate()
[13]: df = spark.read.csv("data/Microdados do Censo da Educaç o Superior 2021/dados/
       →MICRODADOS_CADASTRO_IES_2021.CSV", sep=';', header=True, inferSchema=True)
[15]: for col in df.columns:
          df = df.withColumnRenamed(col, col.lower())
```

```
[16]: df.createOrReplaceTempView('df')
```

2 transformando csv em parquet

```
[17]: df.write.parquet("MICRODADOS_IES_CONSULTA.parquet")
[18]: parquet_df = spark.read.parquet("MICRODADOS_IES_CONSULTA.parquet")
[19]: parquet_df.createOrReplaceTempView("parquet_df")
```

- 3 consultas
- 4 Olhando para o estado de Minas Gerais, quantos municípios têm informações presentes na base de dados?

5 Quantos professores doutores existem em cada cidade de Minas Gerais presente na base de dados

```
[24]: spark.sql("""SELECT no_municipio_ies as municipio, sum(qt_doc_ex_dout) as_

Qtd_Doutores from parquet_df WHERE no_uf_ies = 'Minas Gerais'

group by no_municipio_ies order by Qtd_Doutores DESC""")
```

1	Uberaba	891
	Lavras	812
IS o	Joo del Rei	753
	Ouro Preto	746
	Diamantina	673
+		+
only	showing top 10 rows	

6 Qual a quantidade de docentes com deficiência no estado do Paraná?

```
[23]: spark.sql("SELECT SUM(qt_doc_ex_com_deficiencia) FROM parquet_df WHERE

→sg_uf_ies = 'PR' ")

[23]: +-----+
| sum(qt_doc_ex_com_deficiencia)|
+-----+
| 160|
+-----+
```